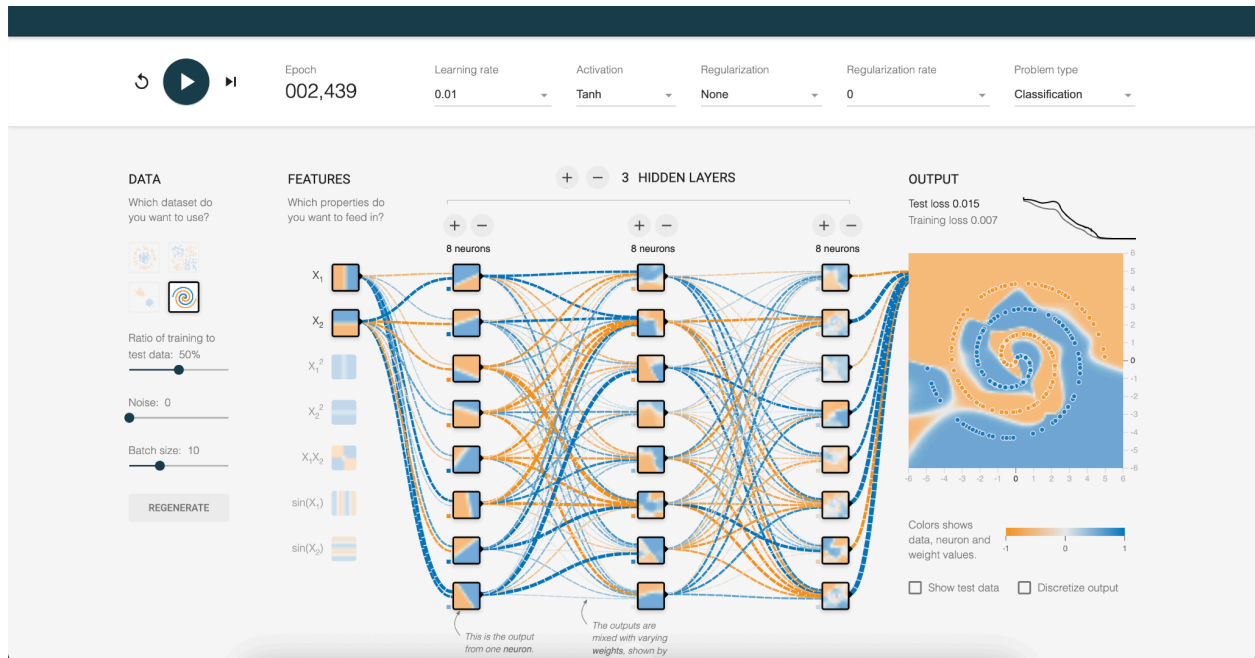


Atividade Playground

Link: <http://playground.tensorflow.org/>

Discente: Lucas Cristiano Calixto Dantas (lccd@cesar.school)



Resultado:

Test loss: 0.015

Training loss: 0.007

Aprendizados:

Ao resolver o dataset *Spiral* no TensorFlow Playground, foi possível perceber o impacto das diferentes variáveis durante o treinamento no modelo e resultados obtidos.

Em relação ao número de camadas e neurônios, esse pareceu ampliar a capacidade da rede de capturar padrões mais complexos, fazendo com que seja absorvida a ideia de que modelos para problemas mais complexos vão acabar necessitando de mais camadas e mais neurônios. Nesse exemplo, com poucas camadas ou poucos neurônios, a rede não conseguia aprender a espiral, resultando em underfitting. Já com 3 camadas de 8 neurônios cada, a rede conseguiu modelar melhor o problema.

O tipo de ativação também pareceu alterar significativamente o resultado obtido: durante as tentativas, a função *tanh* apresentou melhor desempenho que a ReLU. Ao pesquisar a aplicação, deu para perceber que cada uma seria mais adequada para diferentes tipos e características dos problemas. No caso da *tanh* ela parecia lidar melhor com transições suaves e simétricas, o que se assemelha ao padrão em espiral.

O learning rate também teve impacto direto: valores altos (0.1) causavam oscilações e não

estabilizaram a solução, enquanto valores muito baixos (0.001) tornavam o treino muito lento; o valor intermediário (0.01) foi um bom meio termo para os resultados.

Por fim, o parâmetro de regularização mostrou-se pouco necessário neste caso, já ao aplicá-lo, nesse caso, acabava em geral prejudicando a aprendizagem.

Em resumo, aprendi que cada hiperparâmetro influencia diretamente na capacidade do modelo de generalizar e capturar padrões, e que é necessário encontrar um equilíbrio entre profundidade, largura, função de ativação e taxa de aprendizado para obter bons resultados.